

AIエージェント時代の ハーネスエンジニアリングとは

国家資格キャリアコンサルタント
為安圭介

AIの生成量が急激に増大している

OpenAI Codexチームの実証

100万行


5ヶ月間で100万行のソフトウェア開発

0行

手書きのコードは0行

<https://openai.com/index/harness-engineering/>より

AIエージェントが要件整理から実装、テストまでを短期間で処理するようになり、これまで私たちが開発のために投入していた工数と期間が激減している。開発作業を積み上げて工数を請求するようなビジネスは成立が難しくなった。



人間の確認コストがボトルネックに

コード処理量が爆発的に増えるにつれ、ボトルネックは人間の確認時間へ



AIによる価値貢献式

$$V = O - C_{review}$$


- V : ビジネス価値
- O : AIによる出力の総量
- C_{review} : 人間による確認・評価・修正コスト

AIは大量のコードを吐き出すが、既存のアーキテクチャを無視したり、辻褄の合わない実装を混ぜ込んでくる。結果として、AIが書いたコードの仕様の揺れを人間が目で見えて修正する羽目になり、AIの出力の便利さを人間の確認コストが上回る恐れがある。

AIによる価値貢献を最大化するには、AIによる出力結果を最大化し、人間の確認コストを最小化する必要がある。その有力な手法が「ハーネスエンジニアリング」である

ハーネスエンジニアリングとは

AIエージェントの自律性と安全性を両立させるため、人間が望む方向に誘導する「手綱（ハーネス）」となる環境」と「フィードバックループ」を設計する技術。




「エージェントハーネスは、AIモデルを包括し、長期実行タスクを管理するインフラストラクチャです。ハーネスは、プロンプトプリセット、ツール呼び出しの適切な処理、ライフサイクルフック、またはすぐに使用できる機能を提供します」

ハーネスエンジニアリングを構成する3つの柱



1. コンテキスト管理

AIに背景と目的、何をしたいのかを伝えつつ、特定のタスクに必要な仕様や現在の状態だけを精選して渡す仕組み



2. アーキテクチャ制約とガードレール

AIが「やってはいけないこと（依存関係のルール違反など）」を機械的にブロックする仕組み



3. 品質評価と多角的なフィードバック

人間ではなく、自動化されたテスト環境や評価用AI等を使って、AIの出力を継続的に検証・改善する仕組み

コンテキスト管理（段階的開示と設計図の提供）


大量の情報を一度に渡すと、AIの短期記憶（コンテキストウィンドウ）が埋まり、肝心な推論の精度が落ちる。まずは全体像と目次だけを見せ、必要に応じて詳細なナレッジにアクセスさせる。

OpenAIは最初は1つの大きなAGENTS.md
(1,000ページのマニュアル) にすべてを書くアプローチを試したが、失敗した



- ・コンテキストは希少な資源である
- ・すべてが「重要」なとき何も重要でなくなる
- ・分厚いマニュアルは即座に腐る
- ・単一の塊では機械的なチェックに向かない


- ・目的、前提条件、用語定義を「目次」として渡す
- ・詳細な構造化ドキュメントへ誘導する
- ・単体テストをしやすい構造にする



アーキテクチャ制約とガードレール

ドキュメントだけでは、エージェントが生成したコードベースの一貫性を保つことはできない。アーキテクチャの境界を限界に定め、構造テスト等でやってはいけないことをブロックし、境界内でのみエージェントに自律性を許可することで、リリースの高速性と保守性を高める。

OpenAIの事例



エージェントは厳格な境界と予測可能な構造を持つ環境で最も機能を発揮する。


そのため、アプリケーションを厳密なアーキテクチャモデルに基づいて構築。

- ・各ビジネスドメインは固定されたレイヤー群に分割
- ・依存関係の方向性は厳密に検証
- ・許容されるエッジは限定された集合で構成

これらの制約は、カスタムリンターと構造的テストによりCIで自動検出

品質評価と多角的なフィードバック

AIの揺れを人間が目で追う形ではなく、成功条件を固定化し、AIが自らテストし、自律修正する循環を設計する。多角的な評価指標を組み合わせてパイプラインを組み、品質を担保する。



- エラーやログをAIが読み取れる形で渡し、バグの再現と修正検証を自律化
- 評価指標を人間の目に依存せず、ロジックとLLMを組み合わせたパイプラインを構築
- 人間は最終承認と高度な判断に集中する

評価パイプライン



[形式検証]: 完全一致(ロジック型)




[順序検証]: Rouge-L(LLM型)



[意味検証]: コサイン類似度
METEOR (LLM型)


これからのソフトウェア開発ライフサイクル

これからのエンジニアは「宣言的プロンプト」で意図を指定し、AIにバグの再現や修正案の提示を自律的に実行させる。人間はAIが生成したプルリクエストの承認者であり判断者。



新たなエンジニア像に求められるスキル

企業独自の暗黙知をAIが可読できる環境仕様に変換する能力（The Translation Bridge Skill）がコアスキルとなる。



ITエンジニアはインヴァイロメントアーキテクトへ

ツールの導入支援ではなく、AIの価値を最大化しながら人間のコストを継続的に下げる仕組み（再現性のあるハーネス）を提供することが顧客価値となる。

AI開発の下請け競争は激化するが、AIガバナンスと検証の仕組みを提供できるベンダは生き残る



ためやす けいすけ
為安 圭介

NECソリューションイノベータ
ディレクター

NECソリューションイノベータにて、ITサービスによる
価値創造を軸に、事業と組織のマネジメントを担う。

AIコミュニティCDLEをはじめ、複数のコミュニティ運
営を行う傍ら、国家資格キャリアコンサルタントとして
情報発信にも注力し、学びと成長の場作りを実践。

活動拠点は北海道。

参加コミュニティ



趣味・好きなもの



取り組んでいること

- ・AIネイティブな組織づくり
- ・スキルアップの文化づくり
- ・CDLE歴史ブログ
- ・キャリア情報発信